

■ HBM-only ■ H3 ■ Naïve Sparse ■ SPLASH (Ours)

SLO 50 ms

SLO 100 ms

Normalized Goodput

Llama-3-8B

Mixtral-8x7B

DeepSeek-67B

Llama-3-70B

Qwen3-235B

128K

192K

256K

384K

512K

768K

1M

2M

